Estatística para Ciências de Dados

Aula 1: Introdução

Mariana Cúri ICMC/USP mcuri@icmc.usp.br

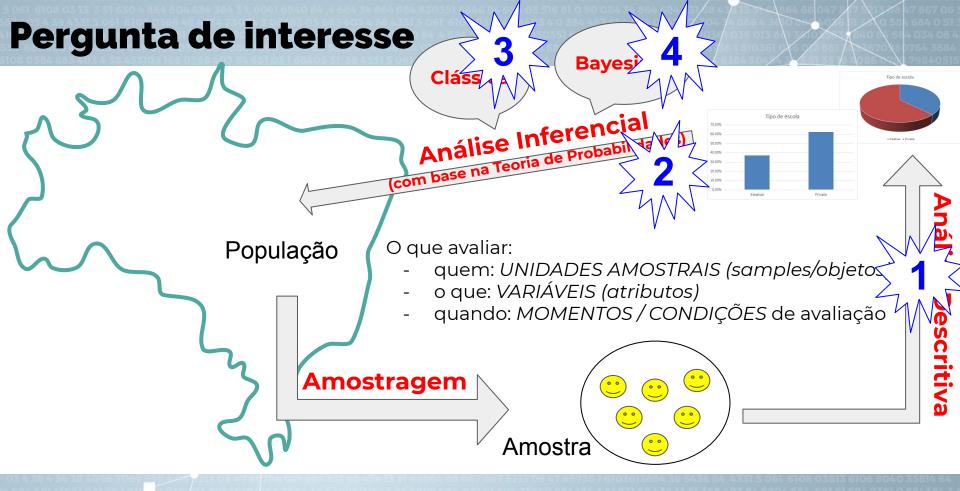




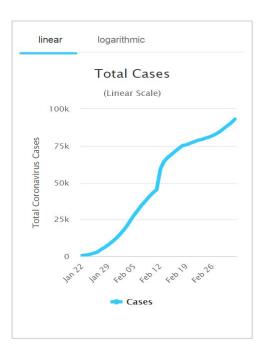


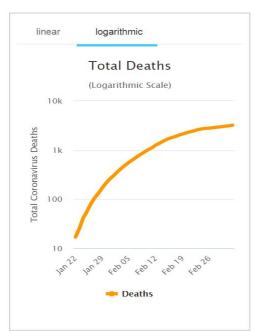
Programa

- O. Introdução e motivação
- Análise descritiva de dados
- 2. Probabilidade
- 3. Inferência estatística
- 4. Inferência bayesiana
- 5. Análise de regressão



A Estatística está em nosso dia-a-dia

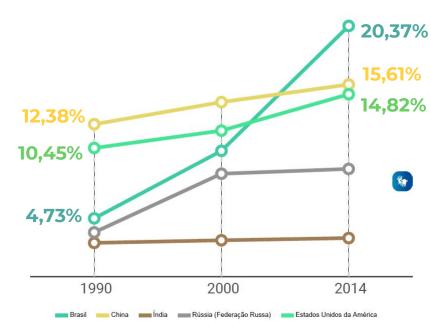




Fonte: https://www.worldometers.info/coronavirus/

Áreas protegidas no total do território nacional

https://paises.ibge.gov.br/#/mapa/comparar/brasil?lang=pt



Fonte: Millennium Development Goals Indicators. United Nations Statistics Division, Department of Economic and Social Affairs.

http://mdgs.un.org/unsd/mdg/Data.aspx. Acessado em: janeiro 2020 (http://mdgs.un.org/unsd/mdg/Data.aspx)



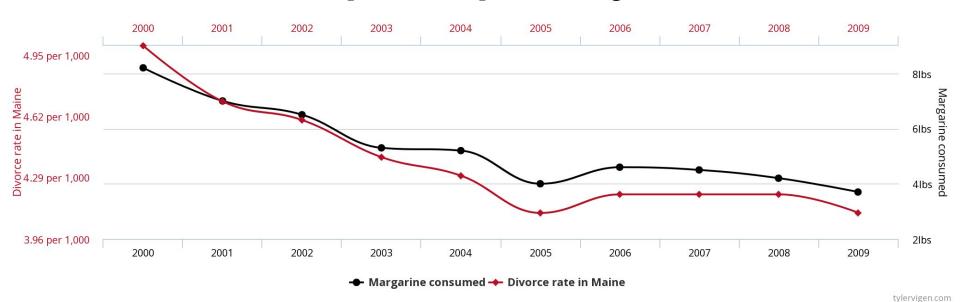




Divorce rate in Maine

correlates with

Per capita consumption of margarine

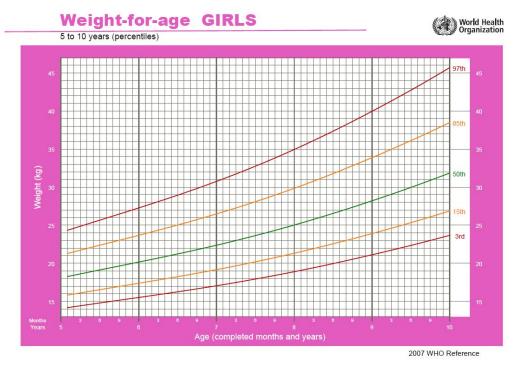


Fonte: https://www.tylervigen.com/spurious-correlations









Intervalo: 3:15 a 4:00

Fonte:

https://www.youtube.com/watch?v=u7E1v24Dllk&t=1142s

Fonte: https://www.who.int/growthref/cht wfa girls perc 5 10years.pdf?ua=1

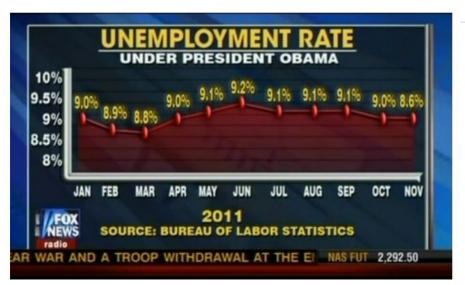




Fox News's unemployment chart: Better

graphics?

By **Erik Wemple**December 12, 2011



Screen grab of chart showing unemployment rate under President Obama. (Fox News)

Fonte: https://www.washingtonpost.com/blogs/erik-wemple/post/fox-newss-unemployment-chart-better-graphics/2011/12/12/gIQAUVgNqO blog.html







Análise Descritiva

Qualitativas: nominais ou ordinais

Tipos de variáveis

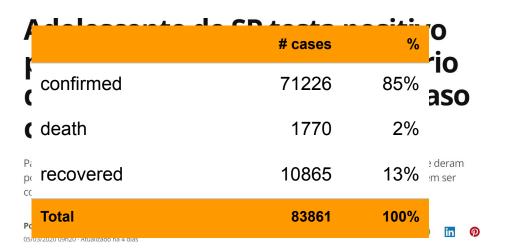
Quantitativas: discretas ou contínuas



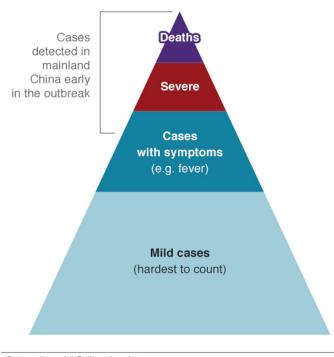
G1 CIÊNCIA E SAÚDE

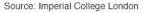
Covid-19 comparada com Sars e Mers

A pesquisa do CCDC afirma que cerca de 80,9% das novas infecções por coronavírus são classificadas como leves, 13,8% como graves e apenas 4,7% como críticas, o que inclui quadro de insuficiência respiratória, falência múltipla dos órgãos e sepse.



Most cases are never counted





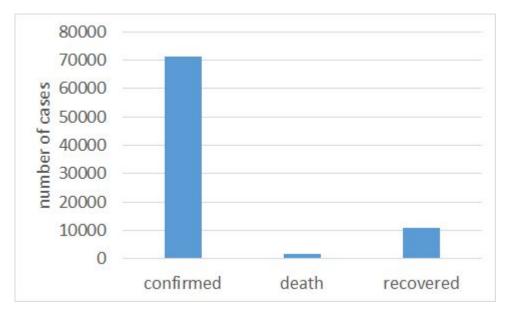


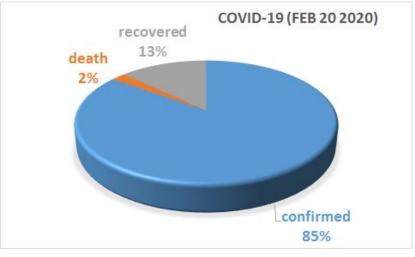




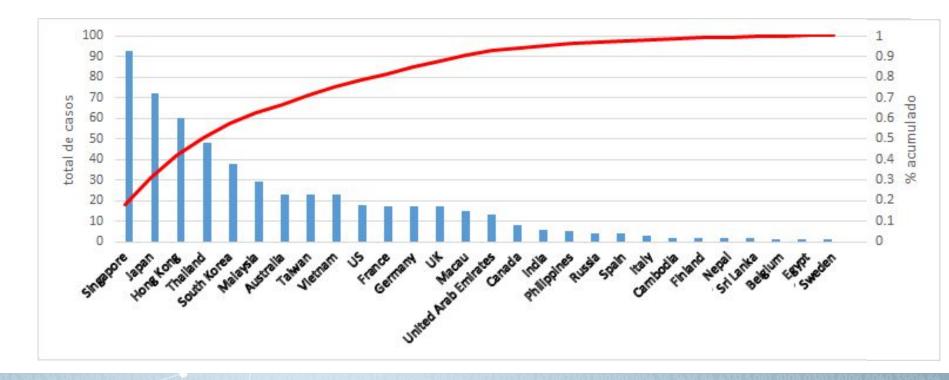


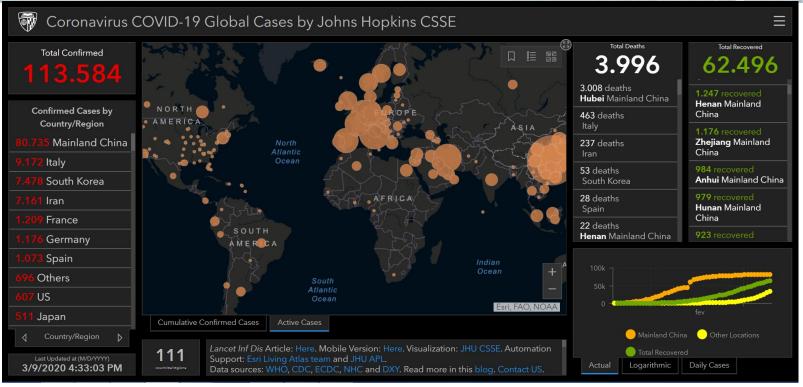
BBC





Casos fora da China Continental: Gráfico de Pareto





Fonte: https://www.arcgis.com/apps/opsdashboard/index.html#/bda7594740fd40299423467b48e9ecf6








Variáveis quantitativas: iner enem



- acesso à educação superior: Sisu, Prouni e convênios com instituições portuguesas
- 4 provas (180 questões) + 1 redação: notas "de 0 a 1000", com média 500 e desvio padrão 100
- prova de matemática e suas tecnologias (2015): 45 questões, n=2901 escolas do estado de SP, 145.389 estudantes
- Perguntas: Existe diferença entre as escolas públicas e privadas? Tem alguma(s) escola(s) pública que se equipara às boas escolas privadas?

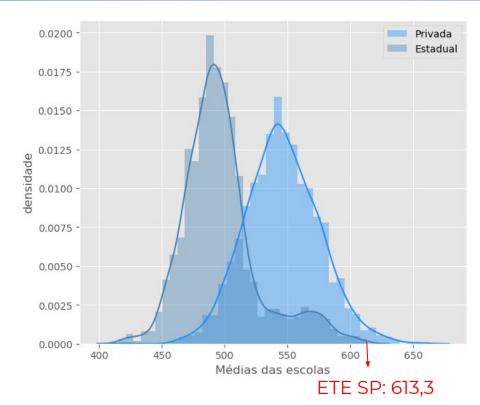


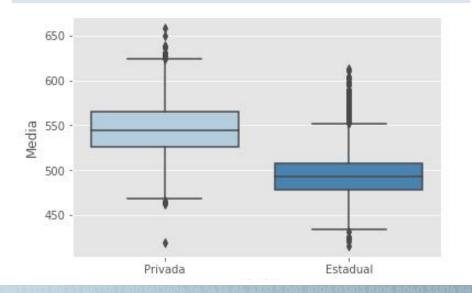
$$egin{aligned} ar{X} &= \sum_{i=1}^n rac{X_i}{n} = 527,6 \ S &= \sum_{i=1}^n rac{(X_i - ar{X})^2}{n-1} = 38,1 & Q_1 = 498,3 \ X &= 2 &= 528,4 \ X_{(1)} &= 415,7 & Q_3 = 555,7 \ X_{(n)} &= 658,3 & CV = rac{S}{ar{X}} 100\% = 7,2\% \end{aligned}$$



Variáveis quantitativas:

Tipo de escola	Média no ENEM	Desvio Padrão	nº de escolas
Estadual	497.1	30.7	1085
Privada	545.8	29.3	1816
Total Geral	527.6	38.1	2901

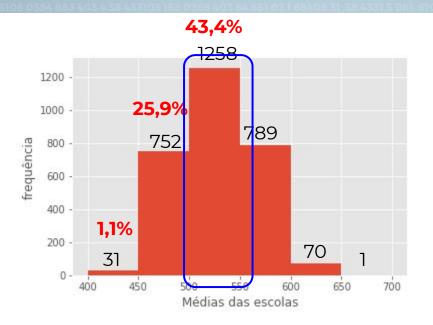








Variáveis quantitativas: Histograma




$$egin{aligned} ar{X} &= rac{31}{2901} 425 + rac{752}{2901} 475 + \ &rac{1258}{2901} 525 + rac{789}{2901} 575 + \ &rac{70}{2901} 625 + rac{1}{2901} 675 = 527,03 \end{aligned}$$

$$S = \sqrt{rac{31}{2900}(425 - 527, 03)^2 + rac{752}{2900}(475 - 527, 03)^2 + \ldots} pprox 41$$



Classes de amplitudes diferentes

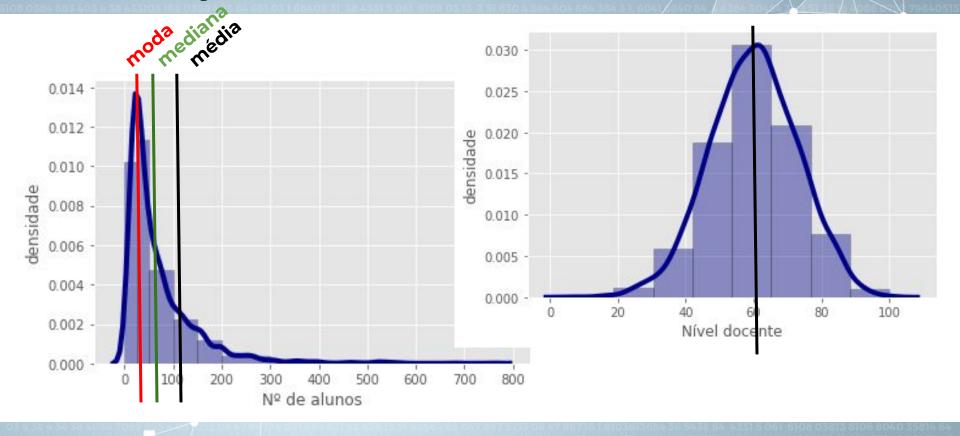
	count	%
(400, 450]	31	1.07
(450, 500]	752	25.92
(500, 550]	1258	43.36
(550, 600]	789	27.20
(600, 650]	70	2.41
(650, 700]	1	0.03



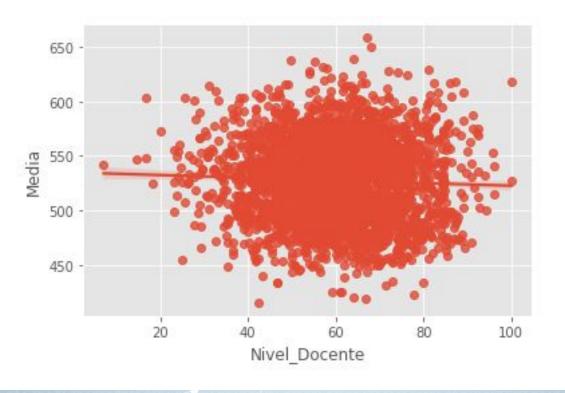




Variáveis quantitativas: (as)simétricas



Associação de variáveis



r=-0,04

Art of Stat

http://www.artofstat.com/webapps.html



